



Orientações para submissão do Plano de Trabalho de Dissertação/Tese

Programas de Pós-Graduação *stricto sensu* da UNIFEI

1. O Plano de Trabalho de Dissertação/Tese é o documento que oficializa a proposta de dissertação/tese do discente, bem como sua orientação/coorientação no Programa de Pós-Graduação (PPG).
2. A partir do ingresso no PPG, todo discente regular tem o prazo máximo de **06 meses** para **submeter seu Plano de Trabalho de Dissertação/Tese** à apreciação da Assembleia do programa.
3. Não submeter o Plano de Trabalho de Dissertação/Tese dentro dos prazos estabelecidos caracteriza situação de desligamento do discente do curso ([Resolução CEPEAd nº 11/2025, Art. 69, V](#)).
4. Quaisquer alterações no Plano de Trabalho de Dissertação/Tese ao longo do curso devem ser oficialmente registradas para que sejam validadas. Ou seja, sempre que couber, o Plano de Trabalho deverá ser enviado para apreciação da Assembleia do PPG.
5. Para submeter o Plano de Trabalho de Dissertação/Tese, o requerente deverá: **fazer uma cópia deste formulário no Drive ou realizar seu download**, preencher as informações solicitadas nas páginas seguintes, baixá-lo em formato .pdf e enviá-lo, por e-mail, à secretaria do PPG. Caso possua orientador ou coorientador externo à UNIFEI, a assinatura dele(s) neste documento deverá ser providenciada pelo aluno previamente à entrega do documento.
6. Uma vez registrado o Plano de Trabalho de Dissertação/Tese pela secretaria do PPG, o próprio discente, o seu orientador (e coorientador, caso possua) e a Coordenação do PPG serão automaticamente comunicados, via e-mail.
7. Somente após assinaturas do discente e de seu orientador (e do coorientador, se houver) e do despacho favorável da Coordenação do PPG, realizados via sistema de protocolo digital da UNIFEI (SIPAC), a secretaria do curso registrará a aprovação do Plano de Trabalho de Dissertação/Tese do discente no SIGAA, oficializando seu orientador e/ou coorientador. A data de início da orientação/coorientação será a mesma da aprovação do Plano de Trabalho de Dissertação/Tese.
8. Para outras informações, o requerente deverá entrar em contato com a secretaria do curso, cujo contato está disponível na página de [contatos da PRPG](#).

PARA USO DA SECRETARIA DO PROGRAMA DE PÓS-GRADUAÇÃO

Assinaturas:

- Discente;
- Orientador (e coorientador, caso possua).

Despacho:

- Coordenação do Programa de Pós-Graduação.

Interessados:

- Discente;
- Orientador (e coorientador, caso possua);
- Coordenação do Programa de Pós-Graduação.

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO
Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO
Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppg.itabira@unifei.edu.br



PLANO DE TRABALHO DE DISSERTAÇÃO/TESE PÓS-GRADUAÇÃO *STRICTO SENSU* DA UNIFEI

NOME COMPLETO DO(A) DISCENTE	NÚMERO DE MATRÍCULA	
Anderson Tadeu de Oliveira Vicente	2026101600	
PROGRAMA DE PÓS-GRADUAÇÃO	CAMPUS	NÍVEL
EEL - Engenharia Elétrica ▾	Itajubá ▾	Doutorado ▾
ÁREA DE CONCENTRAÇÃO	LINHA DE PESQUISA	
Eletrônica	Inteligência Artificial	

PROPOSTA DE ORIENTAÇÃO E COORIENTAÇÃO		
Indicação 1: Pedro Paulo Balestrassi	Nome completo:	UNIFEI
Última titulação: Doutorado	Vínculo/Instituição:	
Indicação 2: Coorientador	Nome completo:	
Última titulação: Doutorado	Vínculo/Instituição:	

Por questões operacionais de registro deste Plano de Trabalho no sistema SIGAA, **somente para orientadores/coorientadores EXTERNOS à UNIFEI**, as informações abaixo são de preenchimento obrigatório (preencher individualmente para cada membro externo).

INFORMAÇÕES DO ORIENTADOR/COORIENTADOR EXTERNO À UNIFEI	
Número do RG/Passaporte:	Órgão emissor (RG/Passaporte):
Número do CPF:	Data de nascimento:
Nacionalidade:	Naturalidade:
Nome completo da mãe:	E-mail principal:



PROPOSTA DE DISSERTAÇÃO/TESE

Título da proposta de dissertação/tese

Manutenção Preditiva baseada em Deep Learning: Análise Probabilística de Vida Útil Remanescente com Otimização Multiobjetivo

Dissertação/Tese associada a projeto de pesquisa registrado na Diretoria de Pesquisa?

() Sim. Projeto com fomento. () Sim. Projeto sem fomento. (X) Projeto não registrado.

Em caso positivo, informe o nome do projeto. Do contrário, informe “não se aplica”.

Detalhamento da proposta

1. Tema e Delimitação

Este Plano de Trabalho de Doutorado propõe o desenvolvimento de um framework de manutenção preditiva para estimar a Vida Útil Remanescente (*Remaining Useful Life*, RUL) por meio de modelos de *Deep Learning*. Em contraste com abordagens puramente determinísticas, o framework proposto visa gerar estimativas probabilísticas de RUL, representando tanto o valor esperado da vida útil quanto a incerteza associada à previsão. As distribuições preditivas resultantes serão utilizadas em modelos de otimização multiobjetivo para apoiar decisões de manutenção que considerem simultaneamente custo, disponibilidade e risco de falha.

A validação experimental inicial será realizada utilizando o conjunto de dados NASA C-MAPSS, que fornece séries temporais multivariadas de motores, divisão entre conjuntos de treinamento e teste, diferentes condições operacionais, ruído de sensores, degradação até a falha no treinamento e um objetivo explícito de prever os ciclos operacionais remanescentes antes da falha (NASA, 2025a; NASA, 2025b).

2. Problema de Pesquisa

A literatura analisada destaca três pontos principais: (i) soluções baseadas em *deep learning* têm sido amplamente investigadas em manutenção preditiva; contudo, a seleção da arquitetura mais adequada para cada aplicação permanece uma decisão técnica relevante, pois o desenvolvimento e a otimização desses modelos ainda envolvem escolha de arquitetura, estrutura, hiperparâmetros e validação experimental (SERRADILLA; ZUGASTI; ZURUTUZA, 2020); (ii) abordagens de RUL baseadas em *deep learning* podem explorar sequências temporais multivariadas de sensores, como demonstrado pelo uso de LSTM para estimação de RUL em Zheng et al. (2017). Entretanto, muitas abordagens de *deep learning* para RUL produzem estimativas pontuais, que não representam explicitamente a natureza probabilística da falha nem as incertezas aleatória e epistêmica associadas ao processo de previsão (SRINIVASAN; ANDRESEN; HOLST, 2023); (iii) decisões de programação de manutenção preditiva podem ser formuladas como modelos de otimização multiobjetivo que integram a predição de RUL ao planejamento da manutenção, buscando minimizar simultaneamente o tempo total de conclusão das manutenções e os custos associados (WANG; LI; ZHAO, 2024).

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO

Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122

E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO

Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809

E-mail: cppq.itabira@unifei.edu.br



O problema de pesquisa consiste em: *Como integrar modelos de deep learning para estimação de RUL, quantificação probabilística de incerteza e otimização multiobjetivo de manutenção em um framework experimentalmente verificável, reproduzível e comparável a baselines determinísticos?*

3. Fundamentação Teórica

Esta pesquisa insere-se no contexto da manutenção preditiva de ativos industriais, com foco na estimação da vida útil remanescente (*Remaining Useful Life* — RUL) a partir de dados operacionais e sinais de sensores. A proposta articula modelos de *Deep Learning*, quantificação de incerteza e otimização multiobjetivo para construir um processo de apoio à decisão em manutenção. Nessa perspectiva, a previsão da RUL não é tratada apenas como um valor isolado, mas como uma informação sujeita a incertezas, que pode ser incorporada ao planejamento de intervenções de forma a considerar, simultaneamente, aspectos como custo, disponibilidade e risco de falha.

A manutenção preditiva utiliza informações obtidas por meio do monitoramento de ativos para apoiar a definição do momento mais adequado para intervenções de manutenção, reduzindo a ocorrência de falhas inesperadas. Em ambientes industriais complexos, métodos baseados em dados têm recebido maior atenção em razão da ampliação do uso de sensores, registros operacionais e recursos computacionais. Serradilla, Zugasti e Zurutuza (2020) destacam que o *Deep Learning* se tornou relevante nesse contexto devido ao crescimento dos dados industriais e à necessidade de monitorar o desempenho dos equipamentos para aprimorar as rotinas de manutenção. Os autores também apontam que a escolha da arquitetura mais adequada para cada aplicação permanece uma tarefa desafiadora, pois envolve diferentes estruturas, hiperparâmetros e formas de validação.

Em sistemas de manutenção preditiva, uma das principais tarefas é estimar por quanto tempo um equipamento ainda pode operar antes de precisar de manutenção ou ser substituído. Esse intervalo é chamado de Vida Útil Remanescente (RUL). Zheng et al. (2017) explicam que a RUL é o intervalo entre o momento atual e o fim da vida útil de um componente, e que prever esse intervalo é fundamental para o gerenciamento e a saúde de máquinas e sistemas. Quando a RUL é estimada de forma adequada, é possível planejar melhor as intervenções, organizar os recursos, evitar manutenções desnecessárias e impedir atrasos em reparos importantes.

Para estimar a RUL, há diferentes abordagens. Uma delas é usar modelos físicos, que tentam descrever matematicamente como o equipamento se desgasta, sofre trincas ou corrosão ao longo do tempo. Contudo, Zheng et al. (2017) apontam que esses modelos nem sempre são fáceis de construir, principalmente quando não se conhece bem como ocorre a falha. Por outro lado, quando se dispõe de volume suficiente de dados históricos, é possível usar métodos baseados em dados, que aproveitam as medições dos sensores e as condições de operação para estimar a RUL.

Nessa situação, as informações coletadas pelos sensores formam uma sequência ao longo do tempo. Ou seja, cada máquina ou peça monitorada gera dados em momentos distintos, o que resulta em séries temporais. Zheng et al. (2017) destacam que, para estimar corretamente a RUL, é preciso construir modelos capazes de captar o comportamento dos dados ao longo do tempo. Sendo assim, os autores sugerem a utilização de redes LSTM, um tipo de rede neural capaz de identificar padrões em sequências e lidar com informações provenientes de diferentes condições, falhas e tipos de desgaste.

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO

Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122

E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO

Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809

E-mail: cppq.itabira@unifei.edu.br



As redes LSTM são um tipo de rede neural desenvolvida para compreender relações ao longo do tempo, inclusive as que se estendem por períodos longos. Quando usadas para prever a RUL, elas recebem como entrada uma sequência de leituras de sensores e devolvem uma estimativa do tempo restante de operação até o fim da vida útil. Assim, a LSTM não analisa cada dado isoladamente, mas sim considera como os sinais mudam ao longo do tempo, o que é essencial para a análise da degradação em equipamentos industriais (ZHENG et al., 2017).

Além das redes neurais recorrentes, existem outros métodos, como os chamados *ensembles* e técnicas de otimização no momento de construir os modelos preditivos. Zhang et al. (2017) sugerem usar um conjunto de *Deep Belief Networks* para estimar a RUL, no qual um algoritmo evolutivo multiobjetivo faz com que várias redes trabalhem em conjunto, equilibrando precisão e diversidade. Isso mostra que combinar diferentes modelos pode ajudar a aprimorar as previsões, especialmente quando os padrões de desgaste variam significativamente.

Apesar dos avanços dos modelos de *Deep Learning* para estimação de RUL, uma limitação recorrente está no uso de estimativas pontuais. Nesse tipo de abordagem, o modelo informa apenas um valor previsto, como uma RUL de 80 ciclos, sem representar explicitamente o grau de incerteza associado à previsão. Srinivasan, Andresen e Holst (2023) observam que muitas abordagens orientadas a dados para RUL concentram-se em previsões de ponto único e não incorporam a natureza probabilística da falha. Essa limitação é relevante porque, em aplicações reais, o processo de degradação envolve incertezas tanto relacionadas ao comportamento do sistema quanto ao próprio modelo preditivo.

Nesse cenário, há dois tipos principais de incerteza. A incerteza aleatória é a que está ligada à própria variação do sistema, como quando peças parecidas falham em momentos distintos. Já a incerteza epistêmica está relacionada ao modelo, aos dados disponíveis e ao que o sistema aprendeu. Segundo Srinivasan, Andresen e Holst (2023), entender de onde vem a incerteza ajuda a interpretar as previsões: se a incerteza epistêmica for alta, o modelo pode estar enfrentando dados diferentes dos que viu durante o treinamento; se for aleatória, trata-se de uma variação natural das falhas.

Quando a incerteza é considerada de forma probabilística, a previsão da RUL deixa de ser apenas uma estimativa pontual e passa a oferecer informações adicionais sobre a confiabilidade do resultado. O modelo pode, em vez de apresentar apenas um valor, apresentar um intervalo de confiança, uma probabilidade de falha em determinado período ou até uma distribuição de possíveis resultados. Della Libera et al. (2024) destacam que, embora os modelos de Deep Learning sejam bastante precisos, é muito difícil atingir 100% de acerto. Além disso, errar para mais ou para menos tem consequências diferentes: superestimar a RUL pode causar falhas inesperadas, e subestimar pode gerar manutenções desnecessárias. Sendo assim, para um bom planejamento, é essencial entender e quantificar essas incertezas.

Uma forma de incorporar incerteza ao cálculo é adaptar as redes neurais convencionais a modelos bayesianos. Della Libera et al. (2024) explicam que as redes bayesianas tratam os parâmetros do modelo como variáveis aleatórias, o que permite calcular intervalos de confiança para as previsões. Essa visão é importante, pois une a previsão da RUL ao conceito de risco: não é suficiente conhecer apenas o valor médio estimado da RUL, é preciso também conhecer a incerteza dessa previsão e qual a chance de ocorrer uma falha antes da próxima janela de manutenção.

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO

Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO

Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppq.itabira@unifei.edu.br



Além das soluções bayesianas, há também alternativas que utilizam a chamada análise de sobrevivência. Lillelund et al. (2024) sugerem estimar a RUL de forma probabilística a partir de dados do tempo até um evento, como a falha. Eles apontam que muitos métodos ainda não lidam com a incerteza e se limitam a previsões pontuais. Outro ponto levantado é o problema dos dados censurados, que ocorre quando não há registro da falha real do equipamento. Isso é comum na manutenção preditiva, pois nem sempre se dispõe de todo o histórico dos ativos até o fim de sua vida útil.

A análise de sobrevivência é especialmente útil na manutenção preditiva porque trabalha diretamente com o tempo até a ocorrência de um evento, como a falha ou substituição de um componente. Lillelund et al. (2024) mostram que a função de sobrevivência fornece uma curva decrescente que representa a probabilidade de o componente continuar operando ao longo do tempo. Assim, é possível estimar a probabilidade de funcionamento após determinado horizonte e utilizar essa informação como base para avaliações de risco.

Mesmo quando a previsão da RUL é precisa e considera as probabilidades, isso, por si só, não resolve o desafio da manutenção. O passo seguinte é transformar essa previsão em uma decisão prática. Wang, Li e Zhao (2024) destacam três grandes desafios na manutenção preditiva: prever corretamente o estado do equipamento ou sua RUL, usar essa previsão no planejamento das manutenções e definir a melhor ordem de execução de cada manutenção, considerando os recursos disponíveis. Isso mostra que prever é apenas o começo de um processo decisório mais amplo. Os autores também sugerem o uso de modelos de programação multiobjetivo para integrar a previsão da RUL ao planejamento da manutenção. Eles utilizam um modelo de *Deep Learning* para prever a RUL e, depois, aplicam técnicas matemáticas de otimização para decidir, simultaneamente, como reduzir tanto o tempo total de manutenção quanto os custos envolvidos. Essa proposta é relevante porque mostra que é possível conectar previsões de RUL a métodos de tomada de decisão bem estruturados.

A otimização multiobjetivo é especialmente indicada para problemas de manutenção, pois as decisões envolvem diferentes interesses e objetivos. Fazer a manutenção muito cedo pode evitar falhas, mas custa mais caro e pode reduzir a vida útil do equipamento. Deixar para depois pode economizar a curto prazo, mas aumenta o risco de falhas inesperadas e de gastos maiores no futuro. Por isso, o ideal é buscar soluções que equilibrem custo, tempo, disponibilidade e risco, em vez de focar apenas em um único objetivo.

Dada essa fundamentação teórica, a tese propõe um framework composto por três etapas. Primeiro, a etapa preditiva: modelos de *Deep Learning* analisam dados de sensores e de condições de operação para estimar a RUL. Depois, vem a etapa probabilística, em que as previsões passam a incluir também a incerteza, seja em forma de intervalos, distribuições ou probabilidades de falha. Por fim, as previsões probabilísticas alimentam um modelo de otimização multiobjetivo que gera alternativas de manutenção, considerando tanto o aspecto técnico quanto o econômico.

Com isso, a principal contribuição teórica esperada desta pesquisa é integrar previsão e decisão levando em conta as incertezas associadas à estimação de RUL. Embora a literatura apresente trabalhos sobre *Deep Learning* para RUL, previsões probabilísticas e otimização multiobjetivo, a proposta é articular esses três pontos em um *framework* que possa ser testado, reproduzido e comparado a abordagens determinísticas tradicionais. Isso permitirá avaliar se a incorporação da incerteza das previsões de RUL

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO

Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122

E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO

Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809

E-mail: cppq.itabira@unifei.edu.br



ao planejamento de manutenção resulta em decisões mais robustas do que aquelas baseadas apenas em estimativas pontuais.

4. Justificativa

A documentação da NASA descreve o C-MAPSS como um conjunto de dados composto por múltiplas séries temporais multivariadas, dividido em subconjuntos de treinamento e teste. Cada série temporal corresponde a um motor distinto, que inicia a operação em condição normal e desenvolve falha ao longo do tempo. No conjunto de treinamento, a falha evolui até a falha do sistema; no conjunto de teste, a série é interrompida antes da falha, sendo fornecido um vetor com os valores verdadeiros de RUL para avaliação. Esse conjunto é adequado para uma etapa inicial de validação por conter subconjuntos com diferentes condições operacionais e modos de falha, como FD001 a FD004 (NASA, 2025b).

Della Libera et al. (2024) afirmam que, além do desempenho preditivo, a quantificação da incerteza característica às predições é importante para o planejamento informado da manutenção. Srinivasan, Andresen e Holst (2023) distinguem a incerteza aleatória do sistema (*aleatoric uncertainty*) e a incerteza epistêmica do modelo (*epistemic uncertainty*), propondo predições probabilísticas de RUL. Lillelund et al. (2024), por sua vez, propõem uma estimativa probabilística de RUL baseada em análise de sobrevivência, com suporte a dados censurados.

A dimensão de otimização multiobjetivo é apoiada por Wang, Li e Zhao (2024), que apresentam modelos de programação de manutenção preditiva capazes de integrar a predição de RUL ao planejamento da manutenção. Os autores formulam objetivos simultâneos relacionados à minimização do tempo total de conclusão das manutenções e dos custos associados à manutenção.

5. Objetivos

5.1 Objetivo Geral:

Desenvolver e avaliar um *framework* de manutenção preditiva baseado em *Deep Learning* capaz de gerar estimativas probabilísticas de RUL e integrá-las a modelos de otimização multiobjetivo para suporte à decisão, utilizando dados públicos verificáveis e um protocolo reproduzível.

5.2 Objetivos Específicos:

- Levantar e organizar a literatura sobre previsão de RUL, *Deep Learning*, incerteza probabilística e otimização multiobjetivo aplicados à manutenção preditiva.
- Preparar os dados do C-MAPSS para os experimentos, considerando os subconjuntos FD001-FD004, a normalização dos sensores, a criação de janelas temporais, a definição dos rótulos de RUL e a divisão em conjuntos de treino, validação e teste.
- Implementar modelos determinísticos de referência para a previsão de RUL, incluindo arquiteturas como LSTM e modelos convolucionais, quando adequados aos experimentos.

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO
Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO
Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppq.itabira@unifei.edu.br



- d) Implementar modelos probabilísticos para previsão de RUL, como redes bayesianas e *deep ensembles*, de modo que as previsões incluam não apenas um valor estimado, mas também uma medida de incerteza.
- e) Avaliar os modelos considerando o erro de previsão, a qualidade dos intervalos probabilísticos, a calibração das estimativas e o comportamento dos resultados sob diferentes condições operacionais e modos de falha.
- f) Formular e testar modelos de otimização multiobjetivo que utilizem estimativas de RUL e respectivas incertezas para apoiar decisões de manutenção, considerando critérios como custo, tempo e risco de falha.
- g) Organizar os códigos, as configurações e a documentação dos experimentos em um repositório público (seguindo os padrões da Open Science) para permitir a reprodução dos principais resultados.

6. Metodologia

6.1 Revisão de Literatura e Protocolo de Busca: A pesquisa começará com uma revisão técnica da literatura sobre RUL, *Deep Learning*, quantificação de incerteza e otimização multiobjetivo na manutenção preditiva. Serão registradas buscas nas bases Scopus, ACM Digital Library, IEEE Xplore e arXiv, conforme disponibilidade de acesso. Para cada referência utilizada, serão anotados: título, autores, ano, DOI ou identificador do arXiv, base ou página consultada, trecho utilizado como evidência e data de acesso.

6.2 Fontes de Dados (Datasets): A base inicial dos experimentos será o C-MAPSS, disponibilizado pela NASA. A documentação oficial descreve o conjunto como composto por séries temporais multivariadas, divididas em subconjuntos de treinamento e de teste. Cada série temporal corresponde a um motor; há três configurações operacionais que afetam o desempenho, a presença de ruído nos sensores e os valores verdadeiros de RUL fornecidos para avaliação no conjunto de teste. Os subconjuntos FD001 a FD004 apresentam diferentes combinações de condições operacionais e modos de falha, o que permite avaliar o comportamento dos modelos em cenários de complexidade distinta.

6.3 Pré-Processamento: o pré-processamento incluirá inspeção dos dados, normalização com base nas estatísticas do conjunto de treinamento, tratamento das condições operacionais, quando necessário, criação de janelas temporais, definição dos rótulos de RUL e separação entre treino, validação e teste. Cada etapa será versionada para permitir rastreabilidade. Caso algum sensor seja removido, a decisão será justificada por análise registrada no experimento, por exemplo, baixa variância, comportamento constante ou ausência de contribuição relevante para a previsão.

6.4 Modelagem determinística: serão implementados modelos determinísticos para estimação pontual de RUL. A LSTM será utilizada como uma das arquiteturas de referência por ser adequada ao tratamento de sequências temporais de sensores, conforme discutido por Zheng et al. (2017). Também serão considerados modelos convolucionais quando o janelamento temporal permitir a extração de padrões locais nos sinais. Esses modelos servirão como *baselines* para comparação com as versões probabilísticas.

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO
Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO
Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppq.itabira@unifei.edu.br



6.5 Modelagem probabilística: a etapa probabilística buscará produzir não apenas um valor estimado de RUL, mas também uma medida de incerteza associada à previsão. Para isso, serão avaliadas abordagens como *deep ensembles*, *Monte Carlo dropout* e redes neurais bayesianas, conforme a possibilidade experimental. A escolha dessas abordagens é apoiada por trabalhos que apontam as limitações das previsões pontuais e propõem estimativas probabilísticas de RUL, incluindo a distinção entre incerteza aleatória e epistêmica. Modelos baseados em análise de sobrevivência também poderão ser avaliados como alternativa metodológica, especialmente quando o protocolo experimental permitir representar o problema como tempo até evento ou lidar explicitamente com dados censurados.

6.6 Otimização multiobjetivo: a etapa de decisão utilizará as estimativas de RUL e suas respectivas incertezas como entrada para modelos de otimização multiobjetivo. Serão considerados objetivos como custo de manutenção, tempo ou atraso de atendimento e risco de falha antes da intervenção. Wang, Li e Zhao (2024) serão usados como referência principal para a integração entre a predição de RUL e o planejamento multiobjetivo, especialmente por formularem modelos MILP que minimizam simultaneamente o tempo total de conclusão das manutenções e os custos de manutenção. A inclusão explícita do risco de falha será tratada como uma extensão desta pesquisa, com base nas estimativas probabilísticas de RUL.

6.7 Avaliação: a avaliação dos modelos preditivos considerará métricas de erro, como MAE e RMSE. Para os modelos probabilísticos, serão avaliadas a cobertura empírica dos intervalos, a largura média dos intervalos, a calibração das estimativas e a log-verossimilhança negativa quando o modelo fornecer uma densidade preditiva. Na etapa de otimização, os resultados serão analisados por meio das fronteiras de Pareto, de testes de sensibilidade e da comparação entre decisões baseadas em RUL pontual e em RUL probabilística.

6.8 Reprodutibilidade: o projeto manterá controle de versão dos códigos, registro do ambiente computacional, sementes pseudoaleatórias, scripts de ingestão e de processamento de dados, arquivos de configuração e logs de execução. Resultados que não puderem ser reproduzidos no mesmo protocolo não serão utilizados como evidência principal.

7. Referências Bibliográficas

DELLA LIBERA, Luca; ANDREOLI, Jacopo; DALLE PEZZE, Davide; RAVANELLI, Mirco; SUSTO, Gian Antonio. **Bayesian Deep Learning for Remaining Useful Life Estimation via Stein Variational Gradient Descent.** arXiv preprint, arXiv:2402.01098, 2024. DOI: 10.48550/arXiv.2402.01098.

LILLELUND, Christian Marius; PANNULLO, Fernando; JAKOBSEN, Morten Opprud; MORANTE, Manuel; PEDERSEN, Christian Fischer. **A probabilistic estimation of remaining useful life from censored time-to-event data.** arXiv preprint, arXiv:2405.01614v1, 2024. DOI: 10.48550/arXiv.2405.01614.

NASA. **Prognostics Center of Excellence Data Set Repository.** Washington, DC: National Aeronautics and Space Administration, 2025a. Disponível em: <https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/>. Acesso em: 05 abril 2026.

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO
Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO
Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppq.itabira@unifei.edu.br



NASA. **CMAPSS Jet Engine Simulated Data**. NASA Open Data Portal, 2025b. Disponível em: <https://data.nasa.gov/dataset/cmapss-jet-engine-simulated-data>. Acesso em: 05 abril 2026.

SERRADILLA, Oscar; ZUGASTI, Ekhi; ZURUTUZA, Urko. **Deep learning models for predictive maintenance: a survey, comparison, challenges and prospect**. arXiv preprint, arXiv:2010.03207, 2020.

SRINIVASAN, Ahbishek; ANDRESEN, Juan Carlos; HOLST, Anders. **Ensemble Neural Networks for Remaining Useful Life (RUL) Prediction**. arXiv preprint, arXiv:2309.12445, 2023. DOI: 10.48550/arXiv.2309.12445.

WANG, Lubing; LI, Butong; ZHAO, Xufeng. **Multi-objective predictive maintenance scheduling models integrating remaining useful life prediction and maintenance decisions**. *Computers & Industrial Engineering*, v. 197, 2024. DOI: 10.1016/j.cie.2024.110581.

ZHANG, Chong; LIM, Pin; QIN, A. K.; TAN, Kay Chen. **Multiobjective Deep Belief Networks Ensemble for Remaining Useful Life Estimation in Prognostics**. *IEEE Transactions on Neural Networks and Learning Systems*, v. 28, n. 10, p. 2306-2318, 2017. DOI: 10.1109/TNNLS.2016.2582798.

ZHENG, Shuai; RISTOVSKI, Kosta; FARAHAT, Ahmed; GUPTA, Chetan. **Long Short-Term Memory Network for Remaining Useful Life Estimation**. In: *IEEE INTERNATIONAL CONFERENCE ON PROGNOSTICS AND HEALTH MANAGEMENT (ICPHM)*, 2017, p. 88-95. DOI: 10.1109/ICPHM.2017.7998311.

Assinatura do orientador externo à UNIFEI
(somente se aplicável)

Assinatura do coordenador externo à UNIFEI
(somente se aplicável)

Itajubá ▾

19 de maio de 2026



Local

Data

CRONOGRAMA DE ELABORAÇÃO DA TESE – ANO 1

ETAPAS	DURAÇÃO (MESES)	ANO 1											
		MESES DO ANO											
		1	2	3	4	5	6	7	8	9	10	11	12
Disciplinas e alinhamento do projeto	6 meses	X	X	X	X	X	X						
Revisão da literatura e protocolo de busca	10 meses	X	X	X	X	X	X	X	X	X	X		
Organização dos dados C-MAPSS	3 meses	X	X	X									
Pré-processamento e pipeline dos dados	5 meses						X	X	X	X	X		
Baselines determinísticos iniciais	4 meses									X	X	X	X

CRONOGRAMA DE ELABORAÇÃO DA TESE – ANO 2

ETAPAS	DURAÇÃO (MESES)	ANO 2											
		MESES DO ANO											
		1	2	3	4	5	6	7	8	9	10	11	12
Finalização de disciplinas e aprofundamento teórico	10 meses			X	X	X	X	X	X	X	X	X	X
Implementação dos modelos determinísticos	6 meses	X	X	X	X	X	X						
Modelagem probabilística de RUL	9 meses				X	X	X	X	X	X	X	X	X
Avaliação de erro, calibração e intervalos	6 meses							X	X	X	X	X	X
Redação parcial e artigo sobre	6 meses						X	X	X	X	X	X	

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO
Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO
Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppg.itabira@unifei.edu.br



revisão/modelos

CRONOGRAMA DE ELABORAÇÃO DA TESE – ANO 3

ETAPAS	DURAÇÃO (MESES)	ANO 3											
		MESES DO ANO											
		1	2	3	4	5	6	7	8	9	10	11	12
Consolidação dos modelos probabilísticos	6 meses	X	X	X	X	X	X						
Formulação da otimização multiobjetivo	5 meses	X	X	X	X	X							
Integração entre RUL probabilística e decisão	7 meses				X	X	X	X	X	X	X		
Experimentos comparativos e análise de sensibilidade	6 meses							X	X	X	X	X	X
Qualificação e submissão de artigo	4 meses				X	X	X	X					

CRONOGRAMA DE ELABORAÇÃO DA TESE – ANO 4

ETAPAS	DURAÇÃO (MESES)	ANO 4											
		MESES DO ANO											
		1	2	3	4	5	6	7	8	9	10	11	12
Validação final do framework	4 meses	X	X	X	X								
Consolidação dos resultados e comparação com baselines	6 meses	X	X	X	X	X	X						
Redação final da tese	10 meses	X	X	X	X	X	X	X	X	X	X		
Submissão de artigos e ajustes finais	7 meses				X	X	X	X	X	X	X		
Revisão final, depósito e defesa	3 meses										X	X	X

Campus Itajubá

PRÓ-REITORIA DE PÓS-GRADUAÇÃO
Av. BPS, 1303, Caixa Postal 50, Pinheirinho, CEP: 37500-903,
Itajubá/MG, Brasil. Tel.: (35) 3629-1122
E-mail: posgrad@unifei.edu.br

Campus Itabira

COORDENAÇÃO DE PÓS-GRADUAÇÃO
Rua Irmã Ivone Drumond, 200, Distrito Industrial II, CEP: 35903-087,
Itabira/MG, Brasil. Tel.: (31) 3839-0806/0809
E-mail: cppq.itabira@unifei.edu.br